

INFORME GERENCIAL - SECOP 2025/2026

Author

Luis Miguel López Pérez, Diana Katherine Huertas Baquero, Sergio Andrés

Sánchez Cardenas

Universidad Central: Maestría en analítica de datos

MATERIA: BIG DATA

INFORME GERENCIAL - SECOP 2025/2026

1) CONTEXTO GENERAL INFORME

El requerimiento general es construir un prototipo de observación de contratación pública integrando fuentes de SECOP II (1° de enero 2025 al 2 de junio 2026), detectando patrones mediante procesamiento de texto no estructurado y publicando resultados analíticos en MongoDB Atlas para alimentar un Dashboard operativo.

2) DESCARGA DE LA INFORMACIÓN

La extracción se realizó mediante las APIs oficiales de SECOP II. Tras pruebas controladas, se ejecutó la descarga masiva de 1'575.975 registros (116 columnas). Los datos se almacenaron inicialmente en formato crudo (JSONL) y se transformaron a Parquet para optimizar consultas. La extracción oficial quedó registrada bajo el periodo 2025_01_01 al 2026-06-02 (Run ID: 20260603T021642Z).

Métrica de Almacenamiento	Valor / Detalle
Formato / Proveedor	Delta Lake (delta)
Tamaño Total	1007.49 MB (Aprox. 1 GB de datos comprimidos)
Archivos Físicos	22 archivos generados
Ubicación Lógica	workspace.default.bronze_secop_ii_contratos_2025

3) LIMPIEZA Y CALIDAD DE DATOS (QA)

Para garantizar la veracidad analítica, se ejecutó un riguroso proceso de limpieza sobre los más de 1.5 millones de registros. Se aplicaron validaciones estrictas: aislamiento de valores financieros atípicos y normalización intensiva del texto (eliminación de espacios dobles y

estandarización a mayúsculas) para evitar duplicidad de entidades. Un foco fundamental fue la **Auditoría de Fechas (QA)**. Se diseñó un esquema de control de calidad analítico (`df_qa_fechas`) encargado de monitorear matemáticamente que todos los eventos cronológicos de los contratos ocurrieran estrictamente dentro del periodo de estudio, y que no existieran vacíos de información en la base. Como se evidencia en la siguiente matriz de control extraída de Databricks, las cuatro variables temporales críticas pasaron exitosamente las pruebas, reportando **0 registros nulos** y demostrando que absolutamente todos los datos procesados se enmarcan correctamente entre los umbrales de 2025-01-01 y 2026-06-02:

Variable Temporal	Fecha Mínima	Fecha Máxima	Reg. Nulos	% Nulos
<code>fecha_firma</code>	2025-01-01	2026-06-01	0	0.0 %
<code>fecha_registro_adicion</code>	2025-01-01	2025-01-02	0	0.0 %
<code>ultima_fecha_adicion</code>	2025-01-01	2025-01-02	0	0.0 %
<code>fecha_creacion_ejecucion</code>	2025-01-01	2026-06-02	0	0.0 %

4) INTEGRACIÓN DE BASES (CAPA GOLD)

Para consolidar la historia de vida completa de cada contrato público, se llevó a cabo una integración masiva de múltiples conjuntos de datos utilizando procesos de transformación y cruce (*Joins*) en Apache Spark. Esta actividad relacionó el núcleo contractual depurado con tres fuentes complementarias vitales, utilizando identificadores únicos:

- **Adiciones Monetarias y de Tiempo:** Consolidación matemática exacta del dinero extra inyectado a los contratos originales.
- **Avances de Ejecución:** Trazabilidad del porcentaje de avance reportado frente al estado operativo real del contrato.

- **Cruce DIVIPOLA (DANE):** Integración con el diccionario geográfico oficial para asignar los códigos correctos de departamentos y municipios, habilitando la futura graficación de mapas.

El procesamiento distribuido permitió ejecutar esta unificación sobre el 100 % del universo de datos (**1'575.975 de registros**) en tiempos óptimos. Adicionalmente, se aplicaron validaciones de integridad referencial para garantizar que la sumatoria total del valor de las adiciones de un solo contrato fuera precisa y consistente. Como resultado final, se construyó la “Tabla Maestra” del proyecto: una estructura unificada y desnormalizada (*Capa Gold*) de **116 columnas enriquecidas**. Esta tabla robusta se convirtió en la fuente oficial de la verdad para correr los algoritmos de priorización y nutrir la posterior migración hacia MongoDB Atlas.

5) TEXTO NO ESTRUCTURADO

Para extraer valor del texto libre (objeto del contrato, justificaciones), se diseñó un motor basado en diccionarios temáticos y expresiones regulares. Esto garantiza un modelo **100 % auditable y explicable**, mitigando los sesgos de una caja negra de inteligencia artificial.

Fases del proceso:

1. **Campo maestro:** Se concatenaron 12 columnas descriptivas dispersas en una variable maestra llamada `texto_busqueda`.
2. **Normalización:** Se eliminaron tildes, signos y caracteres especiales, forzando todo a minúsculas.
3. **Motor de Reglas:** Se definieron 15 macro-tendencias de interés.

Tema / Catego- ría	Ejemplos de términos detectados
Infraestructura	obra, puente, pavimento, vía, construcción, mantenimiento.
Salud	hospital, médico, clínica, medicamentos, insumos médicos.
Tecnología	software, hardware, computadores, licenciamiento, internet.
Educación	colegio, escuela, universidad, docencia, material didáctico.

El algoritmo permite un etiquetado múltiple simultáneo. Operativamente, la contratación se concentró en **Servicios Profesionales** (1,43 millones de referencias temáticas), seguidos de aspectos **Jurídico Administrativos y Seguridad**.

Métrica Evaluada	Resultado Técnico Obtenido
Calidad Integración	0 nulos y 0 vacíos en el campo maestro.
Cobertura Algoritmo	99,16 % de los registros fueron etiquetados con éxito.
Multitemáticos	1.208.528 registros (76,68 %) clasificados en dos o más temas.

6) ÍNDICE DESCRIPTIVO DE PRIORIDAD

Para determinar analíticamente *¿cuáles contratos revisar primero?*, se diseñó un **índice descriptivo** (0 a 100 puntos). Actúa como alerta temprana, sin implicar un fraude judicial de antemano.

```

indice_prioridad =
    score_valor_alto (25 pts)
    + score_adiciones (20 pts)
    + score_avance_bajo (20 pts)
    + score_modalidad (15 pts)
    + score_tema (10 pts)
    + score_texto (10 pts)

```

Metodología: Se utilizaron percentiles matemáticos (P50 a P95) sobre históricos para otorgar el puntaje máximo de valor exclusivamente al top 5 % más costoso del país. Se dividió la urgencia en tres niveles y se habilitó la columna `factores_prioridad` para justificar textualmente cada calificación.

Nivel de Prioridad	Volumen	Índice Promedio	Rango (Mín - Máx)
ALTA (Foco)	3.315 contratos	71,76 puntos	70 a 90 puntos
MEDIA	514.134 contratos	47,68 puntos	40 a 69 puntos
BAJA	1.058.526 contratos	33,39 puntos	14 a 39 puntos

De 1.57 millones de registros totales, la ingeniería de datos redujo magistralmente la carga de revisión humana prioritaria a solo **3.315 contratos críticos. Top 3 del ranking:**

ID del Contrato	Índice	Valor Aprox.	Adiciones
C01.PCCNTR.8059542	90	\$ 37.975 Millones	5 adiciones
C01.PCCNTR.7869283	90	\$ 6.584 Millones	8 adiciones
C01.PCCNTR.7495104	90	\$ 6.415 Millones	5 adiciones

7) MODELO NoSQL EN MONGODB

La base analítica fue exportada a **MongoDB Atlas** (BSON/JSON) para habilitar consumos de baja latencia requeridos por un Dashboard interactivo. **El desafío de la infraestructura (Límite *Free Tier*)** Durante el despliegue (05_SECOP_2025_MODELO_NoSQL_MongoDB_FREE_TIER), la versión gratuita de MongoDB impuso un límite inamovible de **512 MB**. El clúster colapsó a los **173.000 documentos** por desbordamiento. Esto constituye una restricción comercial de hardware, no un fallo de código. En un entorno *Cloud* pago, el script escalaría fluidamente.




Figura 1: *Evidencia de escritura bloqueada al superar la cuota (512 MB) en MongoDB.*

Estrategia Funcional (*Smart Sampling*) Para mitigar la cuota de hardware y materializar la prueba, la versión (FUNCIONAL) implementó:

1. **Muestreo por Prioridad:** Se exportó únicamente la élite crítica: los **50.000** con-

tratos de mayor impacto según el índice.

2. **Recorte (*Truncate*):** El `texto_busqueda` se limitó a 600 caracteres y `objeto_contrato` a 350, liberando memoria vital.
3. **Idempotencia:** Mediante actualización condicional (`upsert=True`), se evitó la duplicidad de datos al re-ejecutar rutinas.

Diseño Documental y Rendimiento La colección central `contratos_operativos` anidó información en sub-objetos (`contrato`, `entidad`, `analitica`). Spark calculó e insertó previamente "vistas materializadas" (`alertas_revision`, `resumen_entidades`) para no saturar al clúster NoSQL con sumatorias en tiempo real. Para dotar al sistema de transaccionalidad, se desplegaron **índices operativos y de texto**. Mediante la validación `explain()` se confirmó que las búsquedas complejas evitan recorridos secuenciales (*Collection Scans*), garantizando tiempos de respuesta instantáneos.

8) DASHBOARD OPERATIVO E INTERACTIVO

El proyecto culminó con el desarrollo de un **Dashboard Operativo e Interactivo**, diseñado para ser el producto de datos final consumido por los usuarios de negocio (entes de control, veedurías ciudadanas y analistas). Este tablero visual fue conectado directamente a las colecciones de **MongoDB Atlas**, alimentándose en tiempo real del modelo documental NoSQL previamente construido.

Diseño y Componentes Visuales

Para garantizar una lectura ágil del panorama de contratación pública, el tablero se estructuró en secciones estratégicas que responden directamente a las necesidades del observatorio:

- **KPIs de Gestión (Tarjetas Superiores):** Monitorean las grandes cifras macroeco-

nómicas. Incluyen el total de contratos cargados, el valor monetario expresado en miles de millones de pesos (B COP), la cantidad exacta de contratos clasificados con prioridad ALTA (foco de auditoría) y el número de expedientes que registran adiciones.

- **Rankings de Actores:** Gráficos de barras horizontales que exponen el *"Top 10 de entidades por volumen de contratos"* y el *"Top 10 de proveedores por valor contratado"*, permitiendo identificar rápidamente monopolios o concentraciones inusuales de presupuesto.
- **Análisis Temático y de Prioridad:** Un gráfico de distribución que segmenta el volumen de contratos según las macro-tendencias detectadas mediante procesamiento de texto (ej. Servicios Profesionales, Seguridad, Tecnología). Se acompaña de un medidor radial que ilustra el porcentaje de participación de los contratos críticos frente al total.
- **Tabla de Alertas de Revisión:** Una tabla detallada que lista los expedientes más urgentes, mostrando el ID del contrato, nivel e índice de prioridad, valor financiero y entidad involucrada, permitiendo ir directamente a la anomalía.
- **Evidencia de Actualización:** Un componente técnico en la zona inferior que lee la colección `metadata_pipeline`, exponiendo el `run_id`, fecha de ejecución, estado (OK) y conteos documentales, garantizando la confianza total en los datos visualizados.

Prueba de Actualización Dinámica (Antes y Después)

Para demostrar la capacidad operativa del sistema frente a la ingesta de nuevos datos, se realizó una prueba de actualización.

Inicialmente, el Dashboard consumió una muestra de **50.000 contratos** (equivalentes a 43.295 B COP). Posteriormente, se re-ejecutó el pipeline de ingeniería en Databricks inyectando un nuevo lote hasta alcanzar los **100.000 contratos** (96.585 B COP).

Como se evidencia en las capturas posteriores, el Dashboard absorbió el incremento volu-

métrico de forma estable para la prueba: los KPIs se actualizaron de forma automática, los rankings recalcularon sus líderes y, lo más importante, la evidencia de actualización reflejó el nuevo identificador de corrida (`run_id`) y los nuevos conteos. Esto demuestra una arquitectura es ágil, resiliente y 100 % funcional.



Figura 3: Dashboard Operativo: Vista inicial con carga optimizada de 50.000 contratos prioritarios.




Figura 4: Dashboard Operativo: Vista actualizada dinámicamente tras la nueva ingesta de 100.000 contratos.

9) CONCLUSIONES Y RESPUESTAS ESTRATÉGICAS

El diseño y visualización de este proyecto se fundamenta en un principio analítico, donde la revisión no simboliza fraude o corrupción, dado esto se plantean para el análisis unas preguntas las cuales son obtenidas con el dashboard final del proyecto,este proyecto señala expedientes que, por su alta complejidad financiera, múltiples modificaciones temporales (adiciones), o falta de claridad en su documentación, requieren una veeduría prioritaria.

– ¿Qué contratos recientes deberían revisarse primero?

Debería iniciarse exclusivamente por aquellos **3.315 contratos** catalogados con *Prioridad ALTA*. Especialmente la élite del ranking (Top 3 liderado por expedientes como el C01.PCCNTR.8059542 con 90 puntos), ya que combinan los mayores riesgos en la contratación.

– **¿Qué proveedores concentran más valor contratado?**

Se demuestra que gigantes corporativos e institucionales acaparan las mayores sumas. Proveedores como *GECELCA S.A. E.S.P.*, bancas privadas (*Bancolombia*, *Banco Davivienda*) y corporaciones de infraestructura (*Empresa de Desarrollo Urbano de Medellín*) acumulan astronómicas sumas de presupuesto en la punta del ranking, superando los billones de pesos.

– **¿Qué entidades tienen más contratos con adiciones?**

Al analizar el volumen transaccional, entidades de altísima operativa como la *Unidad Administrativa Especial*, diversas *Alcaldías Municipales* (ej. *Ibagué*) y el *Departamento Nacional de Planeación* lideran el volumen masivo de adiciones.

– **¿Qué temas aparecen con frecuencia en los objetos contractuales?**

Se determinó que la administración pública colombiana se soporta casi en su totalidad en **Servicios Profesionales** (dominando el espectro con más de 1.4 millones de apariciones), seguidos de lejos por los rubros de **Seguridad y Vigilancia**, **Educación y Tecnología**.

– **¿Qué contratos mezclan alto valor, adiciones, baja ejecución o textos poco claros?**

Al analizar la *Tabla de Alertas de Revisión* del Dashboard interactivo, se identifican casos concretos que son críticos de alertas, obligando a una revisión exhaustiva. Destacan los siguientes expedientes:

- **C01.PCCNTR.7486414**: A cargo del Distrito Especial de Ciencia, Tecnología e Innovación, con un altísimo valor de **\$23.284 millones** (Puntaje: 85).

- **C01.PCCNTR.7495104**: Del Departamento Nacional de Planeación (DNP), por valor de **\$6.415 millones** alcanzando **90 puntos** (alerta máxima).
- **C01.PCCNTR.7576705**: Del ICBF Regional, con un presupuesto de **\$2.229 millones** (**90 puntos**).
- **C01.PCCNTR.7367170**: También del Distrito Especial, con **\$1.724 millones** (**90 puntos**).

Estos contratos individuales son la evidencia donde se ha detectado una intersección crítica y demostrable entre alto presupuesto, múltiples modificaciones y avance financiero nulo.

- **¿Cómo mostrar esta información en un tablero sin rehacer manualmente todos los cruces?**

El secreto está en entregarle al tablero la información lista para su uso e interpretación. En lugar de hacer cálculos pesados en tiempo real, el sistema automatiza previamente toda la limpieza, los cruces y las fórmulas de riesgo matemático operando como una fábrica tras bambalinas. Luego, guarda únicamente los resultados y resúmenes finales en la base de datos (MongoDB). Así, el Dashboard carga al instante mostrando las conclusiones. Y lo mejor: si mañana llegan datos nuevos, el robot repite el proceso solo y las gráficas se actualizan sin ninguna intervención humana.

Hallazgos, Límites y Recomendaciones

Para garantizar la total transparencia e interpretación de los datos, se declaran los siguientes límites y se proponen recomendaciones de escalabilidad:

- 1. Restricciones de Hardware (Free Tier):** El límite físico de 512 MB de la capa gratuita de MongoDB Atlas restringe la posibilidad de poner el universo completo (1.57 millones de datos) a disposición interactiva del ciudadano, forzando un diseño de

muestreo inteligente (*smart sampling*). **Recomendación:** Migrar a un entorno *Cloud Paid Tier* (AWS o Azure) para liberar el potencial absoluto de toda la base histórica o realizar el pago de software MongoDB Atlas.

2. **Evolución del Motor de Texto:** Actualmente, el sistema analiza el texto mediante reglas estructuradas y diccionarios, lo que es revisable pero rígido. Pese a la normalización, un 0.8 % de contratos carecen de tema por descripciones humanas vacías. **Recomendación:** Evolucionar hacia un modelo semántico (Inteligencia Artificial LLM) entrenado con jerga jurídica colombiana, capaz de entender el contexto aunque el funcionario escriba con ambigüedad.
3. **Ponderación de Riesgos:** Los pesos de la fórmula (ej. otorgar 25 puntos al valor financiero) nacen de heurística y experiencia de negocio. **Recomendación:** En iteraciones futuras, estos pesos estáticos deberían ser reemplazados por un modelo de Machine Learning (*Random Forest* o *Gradient Boosting*) que asigne pesos dinámicos según el comportamiento anómalo histórico de la plataforma SECOP.

Referencias

- Colombia Compra Eficiente. (2026a). *SECOP II - Contratos Electrónicos*. Datos Abiertos Colombia. <https://www.datos.gov.co/resource/jbjy-vk9h.json>
- Colombia Compra Eficiente. (2026b). *SECOP II - Detalle de Ejecución de Contratos*. Datos Abiertos Colombia. <https://www.datos.gov.co/resource/mfmm-jqmq.json>
- Colombia Compra Eficiente. (2026c). *SECOP II - Modificaciones a Contratos Electrónicos*. Datos Abiertos Colombia. <https://www.datos.gov.co/resource/cb9c-h8sn.json>
- Databricks Inc. (2026). *Databricks Data Intelligence Platform*. <https://www.databricks.com>
- Departamento Administrativo Nacional de Estadística [DANE]. (2026). *DIVIPOLA - Códigos de Municipios y Departamentos*. Datos Abiertos Colombia. <https://www.datos.gov.co/resource/gdxc-w37w.json>
- MongoDB Inc. (2026). *MongoDB Atlas: Fully Managed Cloud Database*. <https://www.mongodb.com/atlas>